

# ساختار تقسیم‌بندی داده و قالب فایل JSON

پروژه سگمنتیشن پولیپ بر پایه چارچوب MS-SAM-LESS

پایان‌نامه کارشناسی ارشد – مهندسی کامپیوتر، گرایش هوش مصنوعی

۶ مهر ۱۴۰۵

## فهرست مطالب

|       |                                          |   |
|-------|------------------------------------------|---|
| ۱     | مقدمه                                    | ۲ |
| ۲     | ساختار تقسیم‌بندی داده‌ها                | ۲ |
| ۱.۲   | دیتاست آموزش (TrainDataset)              | ۲ |
| ۱.۱.۲ | تقسیم TrainDataset به آموزش و اعتبارسنجی | ۲ |
| ۲.۲   | دیتاست تست (TestDataset)                 | ۲ |
| ۱.۲.۲ | تست درون‌توزیعی (In-Distribution)        | ۲ |
| ۲.۲.۲ | تست برون‌توزیعی (Out-of-Distribution)    | ۳ |
| ۳     | ساختار درختی داده‌ها                     | ۳ |
| ۴     | ساختار فایل JSON                         | ۳ |
| ۱.۴   | ساختار کلی                               | ۳ |
| ۲.۴   | ساختار هر نمونه                          | ۴ |
| ۳.۴   | مقادیر مجاز dataset_origin               | ۴ |
| ۴.۴   | نمونه کامل فایل JSON                     | ۵ |
| ۵.۴   | نمایش درختی ساختار JSON                  | ۶ |
| ۶.۴   | گروه‌بندی منطقی نمونه‌های test           | ۶ |
| ۵     | توضیحات و نکات کلیدی                     | ۷ |
| ۱.۵   | مسیرهای فایل                             | ۷ |
| ۲.۵   | کلید image_key                           | ۷ |
| ۳.۵   | تفکیک درون‌توزیعی و برون‌توزیعی          | ۷ |
| ۴.۵   | مثال کد برای گروه‌بندی در زمان ارزیابی   | ۷ |
| ۵.۵   | قابلیت گسترش به چند fold                 | ۸ |
| ۶     | خلاصه نهایی                              | ۸ |

## ۱ مقدمه

در این سند، ساختار تقسیم‌بندی داده‌های آموزش، اعتبارسنجی و تست، و همچنین قالب فایل JSON مورد استفاده در پروژه مشخص می‌شود. این ساختار بر اساس پروتکل استاندارد حوزه Polyp Segmentation (مانند PraNet) طراحی شده است تا نتایج پروژه با مقالات معتبر قابل مقایسه باشد.

## ۲ ساختار تقسیم‌بندی داده‌ها

### ۱.۲ دیتاست آموزش (TrainDataset)

دیتاست آموزش شامل دو زیرمجموعه است که از قبل در پروتکل استاندارد جدا شده‌اند:

• **Kvasir-SEG**: ۹۰۰ تصویر

• **CVC-ClinicDB**: ۵۵۰ تصویر

مجموع تصاویر: ۱۴۵۰ تصویر.

#### ۱.۱.۲ تقسیم TrainDataset به آموزش و اعتبارسنجی

هر زیرمجموعه به صورت جداگانه با نسبت 90/10 به دو بخش آموزش و اعتبارسنجی تقسیم می‌شود. سپس بخش‌های آموزش دو زیرمجموعه با هم ترکیب می‌شوند و بخش‌های اعتبارسنجی نیز به همین ترتیب.

| جدول ۱: تقسیم دقیق TrainDataset به آموزش و اعتبارسنجی |       |             |                  |
|-------------------------------------------------------|-------|-------------|------------------|
| زیرمجموعه                                             | مجموع | آموزش (90%) | اعتبارسنجی (10%) |
| Kvasir-SEG                                            | ۹۰۰   | ۸۱۰         | ۹۰               |
| CVC-ClinicDB                                          | ۵۵۰   | ۴۹۵         | ۵۵               |
| مجموع                                                 | ۱۴۵۰  | ۱۳۰۵        | ۱۴۵              |

**دلیل انتخاب نسبت 90/10:** این نسبت رایج‌ترین نسبت در مقالات Polyp Segmentation است و تعادل مناسبی بین حجم داده آموزش و دقت اعتبارسنجی برقرار می‌کند. همچنین با جدا کردن اعتبارسنجی از داخل هر زیرمجموعه، تضمین می‌شود که توزیع داده اعتبارسنجی نماینده هر دو منبع باشد.

### ۲.۲ دیتاست تست (TestDataset)

دیتاست تست شامل پنج زیرمجموعه است که از قبل در پروتکل استاندارد جدا شده‌اند و به دو دسته درون‌توزیعی و برون‌توزیعی تقسیم می‌شوند:

#### ۱.۲.۲ تست درون‌توزیعی (In-Distribution)

این دیتاست‌ها از همان توزیع داده آموزش می‌آیند:

• **Kvasir-SEG**: ۱۰۰ تصویر

• **CVC-ClinicDB**: ۶۲ تصویر

مجموع: ۱۶۲ تصویر.

## ۲.۲.۲ تست برون توزیعی (Out-of-Distribution)

این دیتاست‌ها از توزیع متفاوتی می‌آیند و مدل در طول آموزش آن‌ها را ندیده است:

• **CVC-ColonDB**: ۳۸۰ تصویر

• **ETIS-LaribPolypDB**: ۱۹۶ تصویر

• **CVC-300**: ۶۰ تصویر

مجموع: ۶۳۶ تصویر.

جدول ۲: ساختار کامل دیتاست تست

| دسته        | دیتاست            | تعداد |
|-------------|-------------------|-------|
| درون توزیعی | Kvasir-SEG        | ۱۰۰   |
|             | CVC-ClinicDB      | ۶۲    |
| برون توزیعی | CVC-ColonDB       | ۳۸۰   |
|             | ETIS-LaribPolypDB | ۱۹۶   |
|             | CVC-300           | ۶۰    |
| مجموع       |                   | ۷۹۸   |

**نکته:** در پروتکل استاندارد PraNet، دیتاست CVC-300 به عنوان یک مجموعه تست برون توزیعی مستقل از CVC-ClinicDB در نظر گرفته می‌شود، هرچند برخی منابع آن را زیرمجموعه‌ای از CVC-ClinicDB می‌دانند. در این پروژه نیز از همین قرارداد پیروی می‌شود.

## ۳ ساختار درختی داده‌ها

**نکته مهم:** در TrainDataset نام پوشه‌ها به صورت image (مفرد) و masks (جمع) است، در حالی که در TestDataset نام پوشه‌ها images (جمع) و masks (جمع) است. این تفاوت در کد بارگذاری داده باید لحاظ شود.

**نکته درباره نام Kvasir-SEG:** در ساختار پوشه TestDataset، زیرپوشه مربوط به این دیتاست به اختصار Kvasir نام‌گذاری شده است. اما در فایل JSON و در کل سند، از نام کامل و رسمی Kvasir-SEG استفاده می‌شود تا یکدستی و وضوح حفظ شود. این نام‌گذاری در بخش dataset\_origin نیز به صورت یکسان به کار می‌رود.

## ۴ ساختار فایل JSON

### ۱.۴ ساختار کلی

فایل JSON شامل دو ریشه اصلی است:

۱. **fold0**: شامل دو کلید train و val که هر کدام یک لیست تخت از نمونه‌ها هستند.

۲. **test**: یک لیست تخت از نمونه‌ها. هر نمونه دارای دو کلید اضافی dataset\_origin و distribution است که امکان گروه‌بندی و گزارش‌دهی تفکیکی را فراهم می‌کند.

|                              |                         |
|------------------------------|-------------------------|
| data/                        |                         |
| TrainDataset/                |                         |
| image/                       |                         |
| 1.png                        | (CVC-ClinicDB)          |
| 10.png                       | (CVC-ClinicDB)          |
| cju0u82z3cuma0835wlxrnrv.png | (Kvasir-SEG)            |
| ... (1450 images total)      |                         |
| masks/                       |                         |
| 1.png                        |                         |
| 10.png                       |                         |
| cju0u82z3cuma0835wlxrnrv.png |                         |
| ... (1450 masks total)       |                         |
| TestDataset/                 |                         |
| CVC-300/                     |                         |
| images/ (60 PNG)             |                         |
| masks/ (60 PNG)              |                         |
| CVC-ClinicDB/                |                         |
| images/ (62 PNG)             |                         |
| masks/ (62 PNG)              |                         |
| CVC-ColonDB/                 |                         |
| images/ (380 PNG)            |                         |
| masks/ (380 PNG)             |                         |
| ETIS-LaribPolypDB/           |                         |
| images/ (196 PNG)            |                         |
| masks/ (196 PNG)             |                         |
| Kvasir/                      | نام پوشه در TestDataset |
| images/ (100 PNG) معادل      | (Kvasir-SEG)            |
| masks/ (100 PNG)             |                         |

شکل ۱: ساختار درختی پوشه‌های دیتاست آموزش و تست

## ۲.۴ ساختار هر نمونه

هر نمونه در بخش train و val یک دیکشنری با سه کلید است:

• **image**: مسیر تصویر ورودی

• **mask**: مسیر ماسک سگمنتیشن (اجباری)

• **dataset\_origin**: نام دیتاست مبدأ

هر نمونه در بخش test یک دیکشنری با چهار کلید است:

• **image**: مسیر تصویر ورودی

• **mask**: مسیر ماسک سگمنتیشن (اجباری)

• **dataset\_origin**: نام دیتاست مبدأ

• **distribution**: یکی از دو مقدار "in\_distribution" یا "out\_of\_distribution"

## ۳.۴ مقادیر مجاز dataset\_origin

نکته درباره یکدستی نام‌ها: نام Kvasir-SEG در هر سه بخش train، val و test به صورت یکسان به کار می‌رود. این یکدستی، گروه‌بندی و گزارش‌دهی را ساده‌تر می‌کند و از هرگونه ابهام در تفکیک منبع داده جلوگیری می‌کند.

جدول ۳: مقادیر مجاز کلید dataset\_origin به تفکیک بخش

| بخش                     | dataset_origin    | توضیح               |
|-------------------------|-------------------|---------------------|
| fold0.val / fold0.train | Kvasir-SEG        | دیتاست Kvasir-SEG   |
|                         | CVC-ClinicDB      | دیتاست CVC-ClinicDB |
| test                    | Kvasir-SEG        | تست درون توزیعی     |
|                         | CVC-ClinicDB      | تست درون توزیعی     |
|                         | CVC-300           | تست برون توزیعی     |
|                         | CVC-ColonDB       | تست برون توزیعی     |
|                         | ETIS-LaribPolypDB | تست برون توزیعی     |

#### ۴.۴ نمونه کامل فایل JSON

```

1 {
2   "fold0": {
3     "train": [
4       {
5         "image": "data/TrainDataset/image/1.png",
6         "mask": "data/TrainDataset/masks/1.png",
7         "dataset_origin": "CVC-ClinicDB"
8       },
9       {
10        "image": "data/TrainDataset/image/cju0u82z3cuma0835wlxrnrv.png",
11        "mask": "data/TrainDataset/masks/cju0u82z3cuma0835wlxrnrv.png",
12        "dataset_origin": "Kvasir-SEG"
13      }
14    ],
15    "val": [
16      {
17        "image": "data/TrainDataset/image/10.png",
18        "mask": "data/TrainDataset/masks/10.png",
19        "dataset_origin": "CVC-ClinicDB"
20      },
21      {
22        "image": "data/TrainDataset/image/cju15wdt3zla10801odjiw7sy.png",
23        "mask": "data/TrainDataset/masks/cju15wdt3zla10801odjiw7sy.png",
24        "dataset_origin": "Kvasir-SEG"
25      }
26    ]
27  },
28  "test": [
29    {
30      "image": "data/TestDataset/Kvasir/images/cju0u82z3cuma0835wlxrnrv.png",
31      "mask": "data/TestDataset/Kvasir/masks/cju0u82z3cuma0835wlxrnrv.png",
32      "dataset_origin": "Kvasir-SEG",
33      "distribution": "in_distribution"
34    },
35    {
36      "image": "data/TestDataset/CVC-ClinicDB/images/100.png",
37      "mask": "data/TestDataset/CVC-ClinicDB/masks/100.png",
38      "dataset_origin": "CVC-ClinicDB",
39      "distribution": "in_distribution"
40    }
  ]
}

```

```

۴۱     },
۴۲     {
۴۳         "image": "data/TestDataset/CVC-300/images/149.png",
۴۴         "mask": "data/TestDataset/CVC-300/masks/149.png",
۴۵         "dataset_origin": "CVC-300",
۴۶         "distribution": "out_of_distribution"
۴۷     },
۴۸     {
۴۹         "image": "data/TestDataset/CVC-ColonDB/images/1.png",
۵۰         "mask": "data/TestDataset/CVC-ColonDB/masks/1.png",
۵۱         "dataset_origin": "CVC-ColonDB",
۵۲         "distribution": "out_of_distribution"
۵۳     },
۵۴     {
۵۵         "image": "data/TestDataset/ETIS-LaribPolypDB/images/1.png",
۵۶         "mask": "data/TestDataset/ETIS-LaribPolypDB/masks/1.png",
۵۷         "dataset_origin": "ETIS-LaribPolypDB",
۵۸         "distribution": "out_of_distribution"
۵۹     }
۶۰ ]
۶۱ }

```

#### ۵.۴ نمایش درختی ساختار JSON

```

{ | | —
  "fold0" | | | | —
    "train" : [                               <- — | | | لیست تخت
      { image, mask, dataset_origin } | | | —
      { image, mask, dataset_origin } | | | —
      ...
    ] | | | —
    "val" : [                               <- — | | | لیست تخت
      { image, mask, dataset_origin } | | | —
      ...
    ] | | | —
    "test" : [                               <- — | | | لیست تخت
      { image, mask, dataset_origin, distribution } | | | —
      { image, mask, dataset_origin, distribution } | | | —
      { image, mask, dataset_origin, distribution } | | | —
      ...
    ]
  }

```

شکل ۲: نمایش درختی ساختار فایل JSON

#### ۶.۴ گروه‌بندی منطقی نمونه‌های test

اگرچه test یک لیست تخت است، اما هر نمونه با دو کلید dataset\_origin و distribution برچسب‌گذاری شده است. این برچسب‌ها در زمان گزارش‌دهی امکان گروه‌بندی زیر را فراهم می‌کنند:

جدول ۴: گروه‌بندی منطقی نمونه‌های تست

| تعداد | dataset_origin    | distribution        |
|-------|-------------------|---------------------|
| ۱۰۰   | Kvasir-SEG        | in_distribution     |
| ۶۲    | CVC-ClinicDB      |                     |
| ۶۰    | CVC-300           | out_of_distribution |
| ۳۸۰   | CVC-ColonDB       |                     |
| ۱۹۶   | ETIS-LaribPolypDB |                     |
| ۷۹۸   | مجموع             |                     |

## ۵ توضیحات و نکات کلیدی

### ۱.۵ مسیرهای فایل

- مسیرها می‌توانند **نسبی** (نسبت به ریشه پروژه) یا **مطلق** باشند. استفاده از مسیرهای نسبی، پروژه را قابل حمل (portable) می‌کند.
- در زمان خواندن JSON، توصیه می‌شود از `Path(project_root) / sample["image"]` برای ساخت مسیر مطلق استفاده شود.
- جداکننده مسیر در JSON باید / باشد (نه \)، چون در سیستم‌عامل‌های مختلف این جداکننده به صورت خودکار توسط `pathlib` مدیریت می‌شود.

### ۲.۵ کلید `image_key`

در ساختار نمونه، کلید `image` به عنوان نام مودالیتی استفاده می‌شود. در زمان اجرای کد، باید آرگومان `-image_key` به برنامه داده شود تا کد بداند کدام کلید را به عنوان تصویر ورودی بخواند. این طراحی با ساختار مخزن اصلی سازگار است که از کلیدهایی مانند `t1`، `t2`، `flair` استفاده می‌کند.

### ۳.۵ تفکیک درون‌توزیعی و برون‌توزیعی

اگرچه در ساختار JSON تمام نمونه‌های تست در یک لیست تخت قرار دارند، اما کلید `distribution` در هر نمونه این امکان را فراهم می‌کند که در زمان گزارش‌دهی، دو گروه درون‌توزیعی و برون‌توزیعی از هم جدا شوند. در گزارش نهایی، معمولاً دو جدول جداگانه ارائه می‌شود: یکی برای دیتاست‌های درون‌توزیعی (که مدل با آن‌ها آموزش دیده) و دیگری برای دیتاست‌های برون‌توزیعی (که توانایی تعمیم مدل را می‌سنجند).

### ۴.۵ مثال کد برای گروه‌بندی در زمان ارزیابی

برای جدا کردن نمونه‌های درون‌توزیعی از برون‌توزیعی و همچنین تفکیک بر اساس منبع دیتاست، می‌توان از کد زیر استفاده کرد:

```
# Load the split file
with open(split_path, "r") as f:
    split = json.load(f)

test_samples = split["test"]

# Group by distribution type and dataset origin
from collections import defaultdict
groups = defaultdict(lambda: defaultdict(list))
```

```

for sample in test_samples:
    dist = sample["distribution"]
    origin = sample["dataset_origin"]
    groups[dist][origin].append(sample)

# Evaluate each dataset separately
for dist, datasets in groups.items():
    print(f"===_{dist}_===")
    for origin, samples in datasets.items():
        metrics = evaluate(model, samples)
        print(f"_{origin}:_{len(samples)}_samples,_Dice={metrics['dice']:.2f}")

```

## ۵.۵ قابلیت گسترش به چند fold

ساختار fold0 به گونه‌ای طراحی شده که اگر در آینده بخواهی 5-fold cross-validation روی TrainDataset انجام دهی، فقط کافی است fold1، fold2، ... را با نسبت‌های مختلف اضافه کنی، بدون هیچ تغییری در ساختار کلی:

```

{
  "fold0": { "train": [...], "val": [...] },
  "fold1": { "train": [...], "val": [...] },
  "fold2": { "train": [...], "val": [...] },
  "test": [ ... ] <- فقط یک بار تعریف می‌شود
}

```

## ۶ خلاصه نهایی

جدول ۵: خلاصه نهایی تقسیم‌بندی داده‌ها

| تعداد | منبع                                      | بخش JSON           |
|-------|-------------------------------------------|--------------------|
| ۱۳۰۵  | ترکیب CVC-ClinicDB + Kvasir-SEG           | fold0.train        |
| ۱۴۵   | ترکیب CVC-ClinicDB + Kvasir-SEG           | fold0.val          |
| ۱۶۲   | (۶۲) CVC-ClinicDB + (۱۰۰) Kvasir-SEG      | test (درون‌توزیعی) |
| ۶۳۶   | ETIS-LaribPolypDB + CVC-ColonDB + CVC-300 | test (برون‌توزیعی) |
| ۱۳۰۵  |                                           | مجموع آموزش        |
| ۱۴۵   |                                           | مجموع اعتبارسنجی   |
| ۷۹۸   |                                           | مجموع تست          |